

UNIVERSITÀ DEGLI STUDI DI PADOVA
DIPARTIMENTO DI SCIENZE STATISTICHE

Anomaly Detection su Grafi Eterogenei per la Pubblica Amministrazione Italiana

Laboratorio di Statistica con le Aziende 2025

Progetto in collaborazione con **RE-ACT**

Componenti del gruppo:

Tommaso Lazzari
Alberto Bortolato
Guido Gomiero

Data:
Aprile 2026

Indice

1	Introduzione	1
2	Grafo eterogeneo della Pubblica Amministrazione	1
2.1	Pulizia dei dati	3
3	Anomaly Detection su Grafi Eterogenei	4
4	Modello	5
4.1	Encoder relation-aware	5
4.2	Decoder attributivo	8
4.3	Decoder strutturale	8
4.4	Loss	8
4.5	Anomaly score	9
5	Risultati	10
5.1	Analisi delle Aggiudicazioni (AGZ)	11
5.2	Standardizzazione e Interpretazione dell'Errore di Ricostruzione	11
5.3	Validazione Esterna	12
6	Discussione, limiti e sviluppi futuri	14
	Riferimenti bibliografici	16

1 Introduzione

Il seguente lavoro si inserisce nell'ambito della competizione *Laboratorio di Statistica con le Aziende 2025*, promossa dal Dipartimento di Scienze Statistiche dell'Università degli Studi di Padova, con l'obiettivo di favorire l'integrazione tra formazione accademica e applicazioni reali in ambito aziendale e istituzionale.

All'interno di questo contesto, la soluzione proposta si pone l'obiettivo di affrontare una problematica proposta dal centro di ricerca RE-ACT, realtà specializzata nell'utilizzo di metodi innovativi di analisi dei dati per la prevenzione di fenomeni criminali e comportamenti anomali in contesti pubblici e privati. In particolare, il problema affrontato riguarda l'identificazione di comportamenti anomali all'interno della Pubblica Amministrazione italiana, con particolare riferimento ai processi di affidamento e aggiudicazione di appalti pubblici. Il progetto si basa sullo sviluppo di un modello di *anomaly detection* non supervisionato capace di individuare *pattern* anomali nelle relazioni della Pubblica Amministrazione, rappresentate tramite un grafo eterogeneo. L'approccio proposto combina la costruzione di un grafo multi-relazionale con l'applicazione di tecniche di *Graph Neural Network* per l'identificazione automatica di comportamenti potenzialmente anomali.

L'uso di modelli non supervisionati risulta particolarmente opportuno e necessario in questo scenario, in quanto i casi di anomalia non sono noti a priori e l'obiettivo principale è individuare configurazioni relazionali inusuali o inattese all'interno di un sistema complesso. Il modello sviluppato mira quindi a combinare informazioni strutturali e attributive, sfruttando sia le caratteristiche delle singole entità sia le relazioni tra esse, al fine di costruire un punteggio di anomalia interpretabile e utile in contesti investigativi e di prevenzione.

2 Grafo eterogeneo della Pubblica Amministrazione

L'analisi proposta in questo lavoro si basa sulla costruzione di un grafo eterogeneo che rappresenta le relazioni tra i principali attori coinvolti nei processi di affidamento e aggiudicazione degli appalti pubblici italiani. L'utilizzo di una rappresentazione a grafo consente di modellare in modo naturale la complessità del sistema della Pubblica Amministrazione, caratterizzato da numerose entità interconnesse e da relazioni di diversa natura.

A differenza dei grafi tradizionali, in cui tutti i nodi e le relazioni sono dello stesso tipo, un grafo eterogeneo consente di rappresentare diverse tipologie di entità e diverse tipologie di relazioni tra esse. Questo approccio risulta particolarmente adatto nel contesto analizzato, in cui coesistono differenti soggetti istituzionali e operativi, ciascuno con caratteristiche e ruoli specifici [8].

Formalmente, il grafo eterogeneo può essere definito come:

$$G = (V, E, \phi, \psi)$$

dove:

- V rappresenta l'insieme dei nodi
- E rappresenta l'insieme degli archi
- $\phi : V \rightarrow \mathcal{T}_V$ è la funzione che associa ad ogni nodo il proprio tipo
- $\psi : E \rightarrow \mathcal{T}_E$ è la funzione che associa ad ogni arco il proprio tipo

Nel contesto della Pubblica Amministrazione italiana, il grafo costruito include quattro principali tipologie di nodi:

- SA (Stazioni Appaltanti): enti pubblici che pubblicano bandi di gara
- CIG (Codice Identificativo Gara): bandi pubblici o procedure di gara
- AGZ (Aggiudicazioni): esiti delle gare pubbliche
- AG (Aggiudicatari): operatori economici vincitori delle gare

Queste entità sono collegate tra loro attraverso diverse tipologie di relazioni che rappresentano le interazioni reali nel processo amministrativo:

- $SA \rightarrow CIG$ (`publishes`): una stazione appaltante pubblica un bando
- $CIG \rightarrow AGZ$ (`has_award`): un bando produce una o più aggiudicazioni
- $AGZ \rightarrow AG$ (`awarded_to`): un'aggiudicazione è assegnata ad uno o più operatori economici
- $CIG \rightarrow CIG$ (`linked_to`): relazioni tra bandi collegati tra loro

Per consentire una più efficace propagazione delle informazioni all'interno del modello, esclusivamente ai fini algoritmici, sono state inoltre introdotte relazioni inverse esplicite:

- $CIG \rightarrow SA$ (`rev_publishes`)
- $AGZ \rightarrow CIG$ (`rev_has_award`)
- $AG \rightarrow AGZ$ (`rev_awarded_to`)

Questa struttura consente al modello di apprendere informazioni sia in direzione diretta sia in direzione inversa, migliorando la capacità di catturare pattern complessi nelle relazioni.

Ad ogni nodo è inoltre associato un insieme di attributi numerici che ne descrivono le caratteristiche osservabili. La natura e la dimensionalità di tali attributi dipendono dal tipo di nodo considerato, riflettendo le diverse informazioni disponibili per ciascuna entità del sistema.

Il grafo risultante presenta dimensioni particolarmente rilevanti, che rendono necessarie tecniche scalabili di apprendimento su grafi. Maggiori dettagli sul numero di nodi e archi sono visibili in Figura 1.

Dal punto di vista interpretativo, il grafo può essere visto come una rete che rappresenta il funzionamento della Pubblica Amministrazione: le stazioni appaltanti pubblicano bandi di gara,




Figura 1: Rappresentazione grafo

che vengono vinti dagli aggiudicatari attraverso le aggiudicazioni. Attraverso questa struttura è possibile osservare pattern ricorrenti, relazioni frequenti e comportamenti atipici.

L'utilizzo del grafo eterogeneo permette quindi di integrare simultaneamente informazioni strutturali e attributive, fornendo una rappresentazione completa del sistema analizzato. Questa rappresentazione costituisce la base per l'applicazione di tecniche di anomaly detection basate su Graph Neural Networks, descritte nelle sezioni successive.

2.1 Pulizia dei dati

La fase di *preprocessing* ha avuto l'obiettivo di trasformare dati amministrativi eterogenei e rumorosi in matrici numeriche coerenti, utilizzabili come tensori per l'addestramento del modello di *anomaly detection* su grafo eterogeneo. In particolare, il *preprocessing* ha riguardato quattro *dataset* principali: stazioni appaltanti (SA), bandi pubblici (CIG), aggiudicazioni (AGZ) e aggiudicatari (AG).

La prima fase ha previsto la pulizia dei dati, l'eliminazione dei duplicati, la gestione dei valori *missing* e la standardizzazione delle variabili numeriche. Le variabili categoriche sono state convertite mediante *one-hot encoding* (variabili indicatrici), mentre le variabili booleane sono state trasformate in formato numerico binario. Inoltre, per le variabili numeriche con valori mancanti, sono stati introdotti indicatori espliciti che ne segnalassero l'assenza, permettendo al modello di distinguere tra valori osservati e imputati.

Successivamente, è stato effettuato un filtraggio relazionale delle quattro tabelle, mantenendo

esclusivamente le entità per cui fosse possibile ricostruire l'intera catena:

$$SA \rightarrow CIG \rightarrow AGZ \rightarrow AG$$

Questo filtraggio è stato realizzato mediante intersezione iterativa delle chiavi, eliminando tutte le osservazioni incomplete o incoerenti e garantendo la coerenza strutturale del grafo finale.

Infine, per ciascun tipo di nodo è stato assegnato un identificatore numerico progressivo e le informazioni testuali originali sono state salvate in dizionari esterni. In questo modo, le matrici finali contengono esclusivamente variabili numeriche, pronte per essere convertite in tensori, mentre le informazioni identificative vengono conservate separatamente per garantire interpretabilità dei risultati.

Il risultato finale del preprocessing consiste in un insieme di dataset numerici coerenti e relazionalmente compatibili, pronti per la costruzione del grafo eterogeneo e l'addestramento del modello di anomaly detection.

Una descrizione dettagliata delle operazioni di pulizia e costruzione delle covariate è disponibile nel documento dedicato [18].

3 Anomaly Detection su Grafi Eterogenei

L'anomaly detection rappresenta un campo fondamentale della statistica e del machine learning, finalizzato all'identificazione di osservazioni che si discostano in modo significativo dal comportamento atteso. In contesti applicativi complessi, come quello della Pubblica Amministrazione, l'individuazione di anomalie può fornire indicazioni preziose per attività di monitoraggio, prevenzione e analisi del rischio.

Nel contesto tradizionale, l'anomaly detection viene applicata a dati tabellari, nei quali ogni osservazione è descritta da un insieme di variabili. Tuttavia, questo approccio risulta limitato quando le informazioni rilevanti non riguardano soltanto le caratteristiche individuali delle entità, ma anche le relazioni tra esse. Nei sistemi complessi, infatti, comportamenti anomali possono emergere non tanto dalle caratteristiche di un singolo soggetto, quanto dalle modalità con cui esso interagisce con gli altri.

Per questo motivo, negli ultimi anni si è diffuso l'utilizzo di tecniche di anomaly detection su grafi [6, 7, 9], che consentono di analizzare simultaneamente sia le caratteristiche dei nodi sia la struttura delle relazioni. Questo approccio risulta particolarmente adatto per contesti come quello della Pubblica Amministrazione, in cui le relazioni tra enti, gare e operatori economici rappresentano un elemento informativo centrale.

Nel caso dei grafi eterogenei, l'identificazione delle anomalie diventa ancora più articolata, poiché le entità coinvolte sono di natura diversa e le relazioni possono avere significati differenti [1, 2]. In questo contesto, è possibile distinguere tre principali tipologie di anomalie:

- anomalie attributive, che riguardano valori inconsueti nelle caratteristiche dei nodi
- anomalie strutturali, che emergono da pattern di connessione atipici

- anomalie contestuali, che si manifestano quando un comportamento è anomalo rispetto al contesto relazionale

Nel contesto della Pubblica Amministrazione italiana, queste tre tipologie assumono un significato particolarmente rilevante. Un'anomalia attributiva può corrispondere, ad esempio, a una gara con caratteristiche economiche o procedurali insolite. Un'anomalia strutturale può emergere quando determinati operatori economici risultano connessi in modo inusuale a specifiche stazioni appaltanti. Un'anomalia contestuale può manifestarsi quando un comportamento apparentemente normale diventa anomalo nel contesto delle relazioni in cui si inserisce.

Nel presente lavoro, l'obiettivo non è individuare automaticamente comportamenti illegali o irregolari, ma piuttosto identificare configurazioni atipiche che meritano un'analisi più approfondita. In questa prospettiva, l'anomalia viene intesa come una deviazione statistica rispetto ai pattern ordinari, segnalando situazioni che richiedono un approfondimento qualitativo.

Questa distinzione è particolarmente importante in ambito pubblico, dove l'interpretabilità dei risultati rappresenta un requisito fondamentale. Il modello sviluppato in questo progetto è progettato per fornire un punteggio di anomalia interpretabile, che consenta agli analisti di comprendere quali elementi contribuiscono all'individuazione di un comportamento atipico.

Un elemento centrale dell'approccio proposto è l'interpretabilità dei risultati. In particolare, il modello consente di distinguere tra diverse componenti dello score di anomalia, separando il contributo delle caratteristiche dei nodi da quello della struttura del grafo. Questa distinzione permette di comprendere se un'anomalia deriva da attributi inconsueti, da relazioni anomale o da una combinazione di entrambi.

4 Modello

In questa sezione viene descritto il modello proposto per l'anomaly detection su grafi eterogenei. Il modello segue una struttura di tipo autoencoder su grafi eterogenei, composta da un encoder relation-aware e da due decoder distinti: un decoder attributivo e un decoder strutturale relation-specific [3, 4].

L'obiettivo del modello è quello di apprendere una rappresentazione latente per ogni nodo che ne sintetizzi sia le caratteristiche attributive sia la struttura relazionale con i nodi circostanti. Una volta costruite queste rappresentazioni sintetiche (*embedding*), il modello tenterà di ricostruire le informazioni attributive e strutturali originarie di ogni nodo [5]. Le difficoltà di ricostruzione vengono quindi utilizzate per identificare configurazioni anomale. Maggiore sarà il discostamento tra le informazioni e la struttura originaria dei nodi con la loro ricostruzione, maggiore sarà il punteggio di anomalia assegnato.

4.1 Encoder relation-aware

L'encoder apprende *embedding* latenti dei nodi attraverso due strati di *message passing* eterogeneo. Per ogni tipo di nodo $t \in \mathcal{T}_V$ (SA, CIG, AGZ, AG), definiamo la matrice delle *feature* di input




Figura 2: Modello di anomaly detection per grafi eterogenei proposto

come:

$$X^{(t)} \in \mathbb{R}^{N_t \times d_t}$$

dove N_t è il numero di nodi del tipo t e d_t è la dimensione delle feature originali.

L'encoder proposto è composto da due layer consecutivi:

$$H^{(1)} = \text{ReLU}(\text{Conv}_1(X))$$

$$Z = \text{Conv}_2(H^{(1)})$$

Per ogni nodo i , si avrà una rappresentazione vettoriale latente $z_i \in \mathbb{R}^d$ all'interno della quale saranno codificate le informazioni del nodo stesso, ma anche dei nodi ad esso collegati e delle relazioni in cui è coinvolto.

Per fare ciò viene definita una convoluzione, Conv, che definisce per ogni nodo i una rappresentazione latente h_i , che aggrega le rappresentazioni suggerite da tutti gli archi entranti nei nodi target i separati per tipo di relazione, $h_i^{(r)}$.

$$h_i = \sum_{r \in \mathcal{R}(i)} \beta_r h_i^{(r)}$$

dove:

- $\mathcal{R}(i)$ è l'insieme delle relazioni in cui il nodo i è coinvolto come nodo target
- i parametri β_r sono definiti come $\beta_r = \frac{\exp(\gamma_r)}{\sum_{r'} \exp(\gamma_{r'})}$ dove i parametri γ_r sono apprendibili e specifici per tipo di relazione.

Ad esempio, un nodo CIG i è coinvolto come nodo target nelle relazioni **publishes**, **rev_has_award** e **linked_to**; la sua rappresentazione risultante da questo encoder sarà dunque

un'aggregazione delle rappresentazioni suggerite da tutte le relazioni di questi tre tipi in cui è coinvolto

$$h_i = \beta_{\text{publishes}} h_i^{\text{publishes}} + \beta_{\text{rev_has_award}} h_i^{\text{rev_has_award}} + \beta_{\text{linked_to}} h_i^{\text{linked_to}}$$

Le rappresentazioni suggerite dalle diverse relazioni, $h_i^{(r)}$ sono ottenute aggregando le informazioni di tutti i nodi sorgenti collegati al nodo target i attraverso la relazione r (ponderate con un sistema di attenzione relation-aware) e l'informazione contenuta nel nodo target stesso.

$$h_i^{(r)} = \sum_{j \in \mathcal{N}_r(i)} \alpha_{ij}^{(r)} W_r h_j + W_{\text{self}} h_i$$

dove:

- $\alpha_{ij}^{(r)}$ è un coefficiente di attenzione che determina quanto rilevante è l'informazione trasmessa al nodo target i dal nodo sorgente j attraverso la relazione r
- W_r è una matrice di parametri apprendibili di trasformazione del nodo sorgente specifica per la relazione r
- h_j è la rappresentazione in input del nodo sorgente
- W_{self} è una matrice di parametri apprendibili di trasformazione del nodo target
- h_i è la rappresentazione in input del nodo target da aggiornare

Per ottenere i coefficienti di attenzione, $\alpha_{ij}^{(r)}$ l'algoritmo si avvale di score $e_{ij}^{(r)}$:

$$e_{ij}^{(r)} = \text{LeakyReLU} \left(a_r^T [K_r h_i \parallel W_r h_j] \right)$$

dove:

- $\parallel$ indica la concatenazione
- a_r è un vettore di parametri apprendibili
- K_r è una matrice di parametri apprendibili di trasformazione del nodo target specifica per la relazione r

I coefficienti di attenzione vengono normalizzati tramite softmax:

$$\alpha_{ij}^{(r)} = \frac{\exp(e_{ij}^{(r)})}{\sum_{k \in \mathcal{N}_r(i)} \exp(e_{ik}^{(r)})}$$

dove:

- $\mathcal{N}_r(i)$ è l'insieme dei nodi sorgente collegati al nodo i tramite la relazione r

4.2 Decoder attributivo

Il decoder attributivo ricostruisce le feature originali dei nodi, $\hat{x}_i$, a partire dalle embedding latenti risultanti dall'encoder, h_i . La struttura consiste semplicemente in un insieme di Multi Layer Perceptron composti da due layer lineari, uno per ciascun tipo di nodo.

Per ogni tipo di nodo t :

$$\hat{X}^{(t)} = f_t(Z^{(t)})$$

dove f_t è una rete neurale feed-forward:

$$f_t(z) = W_2^{(t)} ReLU(W_1^{(t)} z)$$

dove:

- $W_1^{(t)}$ e $W_2^{(t)}$ sono due matrici di parametri apprendibili

4.3 Decoder strutturale

Il decoder strutturale assegna uno score ad ogni arco utilizzando una funzione bilineare relation-specific.

Lo score per un arco (u, v) è:

$$s_{uv}^{(r)} = z_u^T M_r z_v$$

dove:

- M_r è una matrice di parametri apprendibili specifica per la relazione r
- z_u e z_v sono rispettivamente le embedding del nodo sorgente e del nodo target coinvolti

4.4 Loss

La funzione di perdita che il modello è allenato a minimizzare è composta da due componenti:

$$L = \alpha L_{\text{attr}} + \beta L_{\text{struct}}$$

dove:

- L_{attr} è la funzione di perdita della componente attributiva del modello
- L_{struct} è la funzione di perdita della componente strutturale del modello
- α è un iperparametro che controlla il peso della componente attributiva
- β è un iperparametro che controlla il peso della componente strutturale

La loss attributiva per ogni tipo di nodo t è definita come:

$$L_{\text{attr}}^{(t)} = \frac{1}{N_t} \sum_{i=1}^{N_t} \|x_i^{(t)} - \hat{x}_i^{(t)}\|^2$$

che poi vengono aggregate nella loss attributiva complessiva che risulta essere:

$$L_{\text{attr}} = \sum_{t \in \mathcal{T}_V} \frac{N_t}{N} L_{\text{attr}}^{(t)}$$

dove N è il numero totale dei nodi del grafo.

Per quanto riguarda la componente strutturale, durante il *training* vengono utilizzati:

- archi positivi
- archi negativi generati tramite *negative sampling*

che permettono di calcolare per ogni relazione r la binary cross entropy:

$$L_{\text{struct}}^{(r)} = -\frac{1}{|E_r|} \sum_{(u,v) \in E_r} \left[y_{uv}^{(r)} \log \sigma(s_{uv}^{(r)}) + (1 - y_{uv}^{(r)}) \log(1 - \sigma(s_{uv}^{(r)})) \right]$$

dove:

- E_r è l'insieme degli archi appartenenti alla relazione r
- $s_{uv}^{(r)}$ è lo score attribuito alla relazione r tra gli archi u e v dal decoder strutturale
- $y_{uv}^{(r)}$ vale 1 se esiste un arco r tra i nodi u e v , 0 altrimenti
- $\sigma(\cdot)$ è la funzione *sigmoide* che comprime gli score in valori compresi tra 0 e 1

La loss strutturale totale è infine la somma di tutte le cross entropy relative alle varie relazioni r :

$$L_{\text{struct}} = \sum_r L_{\text{struct}}^{(r)}$$

4.5 Anomaly score

Essendo l'obiettivo dell'algoritmo quello di individuare delle entità anomale all'interno del grafo. Una volta addestrato il modello è necessario attribuire un punteggio ad ogni nodo che ne determini l'atipicità rispetto al resto della complessa struttura. Per ogni nodo i appartenente al tipo t , lo score attributivo viene calcolato come errore di ricostruzione medio delle feature:

$$\text{Score}_{\text{attr}}(i) = \frac{1}{d_t} \sum_{k=1}^{d_t} \left(x_{ik}^{(t)} - \hat{x}_{ik}^{(t)} \right)^2$$

dove:

- $x_i^{(t)}$ rappresenta il vettore delle feature originali del nodo
- $\hat{x}_i^{(t)}$ rappresenta il vettore ricostruito dal decoder attributivo
- d_t è la dimensione delle feature per il tipo di nodo t

Ai fini dell'interpretabilità, la componente attributiva dello score di anomalia può essere ulteriormente scomposta analizzando il contributo delle singole variabili. In particolare, essendo lo score attributivo definito come errore quadratico medio di ricostruzione, è possibile esaminare i singoli termini $(x_{ik}^{(t)} - \hat{x}_{ik}^{(t)})^2$, che rappresentano lo scostamento tra valore osservato e valore previsto per ciascuna feature. Questa decomposizione consente di identificare quali variabili contribuiscono maggiormente all'anomalia del nodo, fornendo un'indicazione interpretabile delle possibili cause del comportamento atipico.

Lo score strutturale viene invece calcolato come media degli errori sugli archi osservati incidenti al nodo i . In particolare, per ogni arco (i, j) appartenente alla relazione r , si considera:

$$\text{Score}_{\text{struct}}(i) = \frac{1}{|N(i)|} \sum_{j \in N(i)} -\log \sigma \left(s_{ij}^{(r)} \right)$$

dove:

- $N(i)$ è l'insieme dei nodi connessi al nodo i
- $s_{ij}^{(r)}$ è lo score prodotto dal decoder strutturale per la relazione r
- $\sigma(\cdot)$ è la funzione sigmoide

Poiché le distribuzioni degli score possono differire significativamente tra i diversi tipi di nodi, le due componenti vengono normalizzate separatamente per ciascun tipo di nodo mediante una trasformazione basata sulla funzione di distribuzione empirica cumulativa (ECDF):

$$\widetilde{\text{Score}}_{\text{attr}}(i) = \text{ECDF}_t(\text{Score}_{\text{attr}}(i))$$

$$\widetilde{\text{Score}}_{\text{struct}}(i) = \text{ECDF}_t(\text{Score}_{\text{struct}}(i))$$

dove $\text{ECDF}_t(\cdot)$ rappresenta la funzione di distribuzione empirica calcolata sui nodi del tipo t .

Lo score finale di anomalia è quindi ottenuto come combinazione lineare delle due componenti normalizzate:

$$\text{Score}(i) = \lambda_{\text{attr}} \widetilde{\text{Score}}_{\text{attr}}(i) + \lambda_{\text{struct}} \widetilde{\text{Score}}_{\text{struct}}(i)$$

dove λ_{attr} e λ_{struct} sono iperparametri che controllano il peso della componente attributiva e strutturale rispettivamente.

Questo consente di utilizzare il modello come strumento di supporto all'analisi, piuttosto che come sistema decisionale automatico, rendendolo particolarmente adatto al contesto della Pubblica Amministrazione.

5 Risultati

In questa sezione si analizzano i risultati dell'applicazione del modello ai dati descritti nella Sezione 1. Ai fini della validazione del modello, i casi più anomali sono stati incrociati con notizie pubbliche, così da trovare riscontri reali ai suggerimenti del sistema.

5.1 Analisi delle Aggiudicazioni (AGZ)

Il punteggio finale di anomalia ci dice quanto ogni singolo caso si allontana da quello che il modello ha imparato a considerare "normale" nel sistema degli appalti. Questo valore è compreso tra 0 e 1: più ci si avvicina a 1, più il comportamento rilevato è atipico e meritevole di approfondimento. Nella Tabella 1, sono riportate le 10 aggiudicazioni con punteggio di anomalia più elevato.

Tabella 1: Top 10 Aggiudicazioni (AGZ) per Score di Anomalia.

Pos.	ID AGZ	Aggiudicatario (AG)	Stazione Appaltante (SA)	Final	Attr.	Struct.
1	1064558	N/D	N/D	0.999999	0.999999	0.999999
2	2211528	IMPRESA INESISTENTE	COMUNE DI CASTELLEONE	0.999998	0.999998	0.999998
3	11934929	CONSORZIO DEI COMUNI TARENTINI	COMUNE DI VALLELAGHI	0.999997	0.999997	0.999995
4	1679785	N/D	N/D	0.999996	0.999996	0.999996
5	415034	N/D	N/D	0.999995	0.999994	0.999999
6	14862235	TIM S.P.A.	ISTITUTO SUPERIORE INDUSTRIE ARTISTICHE	0.999994	0.999993	0.999997
7	2594097	N/D	N/D	0.999993	0.999992	0.999998
8	1192361	N/D	N/D	0.999986	0.999984	0.999996
9	14510133	CENTRO STUDI ENTI LOCALI S.P.A.	COMUNE DI PADOVA	0.999928	0.999925	0.999939
10	15650666	DUAL ITALIA S.P.A.	AZIENDA MUNICIPALE GAS SPA	0.999927	0.999947	0.999845

Equivalenti risultati sono stati ottenuti per ciascun tipo di nodo (SA, CIG, AG, AGZ), organizzati in classifiche separate.

Tuttavia, considerato il modello, le variabili coinvolte e il contesto degli appalti pubblici, riteniamo che la maggiore attenzione sia da fornire ai nodi del grafo rappresentanti le aggiudicazioni, AGZ. Infatti, sebbene qualsiasi entità coinvolta nel processo di aggiudicazione di un bando pubblico possa assumere comportamenti fraudolenti, raramente le variabili che costituiscono i nodi relativi a SA e AG del grafo proposto sono utili a rilevarli (codice fiscale, sede legale, azienda partecipata da enti pubblici, ...). Il loro comportamento e l'eventuale svolgimento anomalo della gara d'appalto è invece molto più facilmente rinvenibile nelle variabili codificate nei nodi del grafo riguardanti le aggiudicazioni (data di aggiudicazione, numero di offerte ammesse, subappalti, ribassi, procedure accelerate, ...). Pertanto, le nostre analisi si concentrano principalmente sui risultati ottenuti riguardanti i nodi AGZ.

5.2 Standardizzazione e Interpretazione dell'Errore di Ricostruzione

Una volta assegnato il punteggio di anomalia a ciascun nodo, è essenziale tentare di comprendere il motivo per il quale il modello ha assegnato tali valori. Per quanto la componente strutturale del punteggio di anomalia sia di difficile analisi, se non andando ad analizzare i punteggi assegnati a ciascun nodo comunicante con quello in analisi, l'identificazione delle anomalie si basa anche sull'errore di previsione attributivo del modello, che, diversamente, è possibile andare ad analizzare dettagliatamente.

Analizzando queste informazioni è subito evidente che tali scostamenti sono sintomatici di:

1. **Anomalie Comportamentali:** Deviazioni reali dalle prassi di mercato o amministrative.
2. **Errori di digitazione:** Inserimenti manuali errati (es. date incoerenti, importi fuori scala) che, tuttavia, costituiscono di per sé un rischio per la trasparenza.

Nella Tabella 2 viene presentato il dettaglio delle prime 5 variabili più anomale per l’aggiudicazione che occupa la prima posizione nella classifica delle anomalie.

Tabella 2: Analisi dello score attributivo per l’Aggiudicazione Top 1 (ID AGZ 1064558).

Variabile (Feature)	Valore Osservato	Valore Previsto	Errore
data_aggiudicazione_definitiva	276.8244	101.9566	30578.7578
data_comunicazione_esito	-0.2044	114.2491	13099.5859
ribasso_aggiudicazione	-0.3816	32.0452	1051.4929
importo_aggiudicazione	-0.0122	9.5114	90.6981
flag_subappalto	0.0000	8.4739	71.8070

Come si può notare, l’anomalia è dettata quasi interamente da errori di ricostruzione significativi sulle date. Il valore osservato (standardizzato) di 277 sulla data di aggiudicazione è un valore del tutto fuori scala, che segnala un errore di inserimento dati o una cronologia amministrativa impossibile. Il modello ha isolato questo caso proprio a causa di queste incongruenze temporali estreme. Inoltre, si nota che per le altre variabili i valori osservati sono marginalmente piuttosto normali (vicini allo 0), ma il modello ha previsto valori più estremi portando ad un aumento dell’errore attributivo.

5.3 Validazione Esterna

Per validare esternamente il modello, le aggiudicazioni con i punteggi di anomalia più elevati sono state verificate tramite fonti aperte (stampa, banche dati istituzionali, atti giudiziari). L’obiettivo non è formulare accuse, ma riscontrare se i segnali individuati corrispondano a fenomeni già noti, rafforzando l’utilità del modello come strumento di prioritizzazione del rischio.

Casi di Maggiore Rilievo tra le Top 100 Aggiudicazioni

IMPRESA INESISTENTE – Comune di Castelleone (score: 0.999998). L’aggiudicatario risulta indicato come “*Impresa Inesistente*”, suggerendo un soggetto non registrato o fittizio. Ciò configura una violazione dei requisiti di partecipazione (D.Lgs. 36/2023, art. 94) e possibili ipotesi di frode. Il modello segnala un’anomalia massima sia attributiva sia strutturale.

RECORDATI RARE DISEASES ITALY S.R.L. – InnovaPuglia S.P.A. (score: 0.999373). InnovaPuglia è stata coinvolta in indagini giudiziarie e contenziosi amministrativi su procedure di gara. L’anomalia deriva dalla scarsa coerenza tra il ruolo della centrale di committenza e un fornitore farmaceutico altamente specializzato.

SER.I.T. S.R.L. – Comune di Villafranca di Verona (score: 0,99969393). L’azienda è stata oggetto di perquisizioni della Guardia di Finanza su disposizione della Procura di Verona per ipotesi di abuso d’ufficio e truffa [11]. La vicenda si intreccia con un lungo contenzioso amministrativo (TAR e Consiglio di Stato) contro il Comune per la realizzazione di un impianto di trattamento rifiuti, segnato da ripetuti provvedimenti sospensivi.

MEDTRONIC ITALIA S.P.A. – Azienda Sanitaria Universitaria Friuli Centrale (score: 0,99936295). L'azienda è stata citata nell'indagine "*Vasi Comunicanti*" su un presunto sistema corruttivo nella fornitura di dispositivi cardiologici (stent e TAVI). Gli inquirenti hanno ipotizzato che le sponsorizzazioni di eventi formativi potessero influenzare le scelte d'acquisto ospedaliere; tuttavia, il procedimento è stato archiviato dal GIP per assenza di riscontri oggettivi [12].

NETWEEK S.P.A. – Museo Nazionale del Cinema – Fondazione Maria Adriana Prolo (score: 0,99919677). L'operatore presenta una situazione finanziaria critica: al 30 aprile 2025, il gruppo riportava un indebitamento netto di 3,7 milioni di euro, a cui si aggiungono 13,5 milioni di debiti tributari scaduti e 5,1 milioni di debiti commerciali non saldati [13]. Tale fragilità economica solleva dubbi sulla sostenibilità finanziaria delle forniture affidate.

SEVEN SOUNDS GROUP – Comune di Tuscania (score: 0,999686). Il Comune di Tuscania è stato oggetto di verifiche da parte di ANAC e Corte dei Conti per sospette irregolarità negli affidamenti tra il 2016 e il 2021 [14]. Sono emersi numerosi affidamenti diretti sotto soglia tramite SmartCIG, con contestazioni riguardanti la determinazione dei prezzi e il possesso dei requisiti da parte degli aggiudicatari.

LA SEMAFORICA S.R.L. – Comune di Tremezzina (score: 0,99966407). L'operatore agisce in un contesto territoriale segnato dalle indagini della Procura di Milano su presunti episodi di corruzione per la variante della Tremezzina [15]. Gli inquirenti ipotizzano un sistema di tangenti a funzionari pubblici per agevolare l'aggiudicazione di grandi appalti infrastrutturali nella stessa area geografica.

ENEL X ITALIA S.R.L. – Comune di Barete (score: 0,99853426). Il caso è legato alla complessa gestione amministrativa della ricostruzione post-sisma, caratterizzata da contenziosi legali. Una disputa sul commissariamento di aggregati edilizi è giunta fino al Consiglio di Stato [16], che ha confermato la legittimità dell'operato comunale, evidenziando però una governance territoriale estremamente frammentata e conflittuale.

ACCORD HEALTHCARE ITALIA S.R.L. – Policlinico Umberto I (score: 0,99852294). L'aggiudicatario opera in un quadro istituzionale critico presso il Policlinico Umberto I, coinvolto in varie inchieste per frode, abuso d'ufficio e falso nella gestione degli appalti e dei bilanci [17]. Le indagini hanno evidenziato gravi lacune nella gestione degli incarichi e nella sicurezza della struttura ospedaliera.

TIM S.P.A. – ISIA (score: 0.999995). Emergono incoerenze tra il profilo del fornitore (telecomunicazioni) e quello della stazione appaltante (formazione artistica). L'anomalia è in gran parte strutturale, indicando una relazione atipica e potenzialmente non competitiva.

ABC FARMACEUTICI S.P.A. – Regione Calabria (score: 0.998636). L’aggiudicazione si inserisce in un contesto regionale già oggetto di indagini (operazione “*Sartoria*”, 2024) su irregolarità negli appalti sanitari. Pur senza legami diretti, il contesto rafforza la rilevanza del segnale.

Aggiudicatari Persone Fisiche su Comuni di Piccole Dimensioni. Ricorre un pattern di aggiudicazioni a persone fisiche in piccoli comuni. Il modello intercetta tali casi per la deviazione rispetto ai profili attesi.

Note Conclusive sulla Validazione

La validazione esterna evidenzia tre aspetti principali. Primo, l’assenza di evidenze pubbliche non implica assenza di rischio, poiché molte irregolarità restano non visibili. Secondo, diversi contesti già segnalati dal modello presentano criticità documentate, suggerendo la capacità di cogliere fragilità sistemiche oltre che anomalie puntuali. Terzo, il caso “*Impresa Inesistente*” mostra limiti nei dati di input (errori o entità fittizie) che rappresentano essi stessi un rischio e richiedono controlli a monte.

Nel complesso, la validazione rafforza il valore del modello come supporto operativo per le autorità di vigilanza (es. ANAC), utile a concentrare le risorse ispettive sui casi più critici.

6 Discussione, limiti e sviluppi futuri

Il modello proposto è concepito come uno strumento di supporto all’analisi e al monitoraggio dei processi della Pubblica Amministrazione, e non come un sistema decisionale automatico. In particolare, l’obiettivo principale è fornire un ranking di configurazioni potenzialmente anomale che possano essere oggetto di ulteriori approfondimenti da parte di analisti, esperti di dominio o autorità competenti. In questo senso, lo score di anomalia deve essere interpretato come un indicatore statistico di deviazione rispetto al comportamento atteso, e non come evidenza di comportamenti irregolari o illeciti.

L’utilizzo operativo del modello può risultare utile in diverse attività, tra cui il monitoraggio preventivo delle procedure di gara, l’individuazione di pattern atipici nelle relazioni tra enti e operatori economici, e la prioritizzazione dei controlli amministrativi. La possibilità di distinguere tra componente attributiva e componente strutturale dello score consente inoltre di fornire indicazioni più interpretabili, facilitando l’analisi delle possibili cause dell’anomalia individuata.

Tuttavia, è necessario adottare alcune cautele nell’interpretazione dei risultati. Le anomalie individuate dal modello possono derivare anche da fattori legittimi, come caratteristiche specifiche del territorio, particolari esigenze amministrative o eventi eccezionali. Per questi motivi, il modello deve essere utilizzato come strumento esplorativo e di supporto decisionale, integrato con competenze di dominio e analisi qualitative. In questo modo, l’approccio proposto può contribuire a migliorare la capacità di monitoraggio e prevenzione, mantenendo al tempo stesso un utilizzo responsabile e consapevole delle tecniche di anomaly detection.

Il lavoro presentato in questo report costituisce quindi un primo passo verso la costruzione di un sistema di *anomaly detection* su grafo eterogeneo applicato alla Pubblica Amministrazione italiana. Pur mostrando una struttura metodologica coerente con il problema affrontato, il progetto presenta alcuni limiti che è opportuno esplicitare con chiarezza, sia per una corretta interpretazione dei risultati sia per delineare possibili sviluppi futuri.

Limiti

Risorse computazionali. Le dimensioni del grafo costruito, che comprende milioni di nodi e relazioni, rendono particolarmente oneroso l'addestramento di modelli neurali su larga scala. Per questa ragione, l'ottimizzazione degli iperparametri è stata necessariamente limitata. Analogamente, anche la profondità e la complessità dell'autoencoder sono state contenute entro una configurazione compatibile con i vincoli di memoria e tempo computazionale.

Qualità e completezza dei dati. Come spesso accade in *dataset* di origine amministrativa, la presenza di valori mancanti, errori di codifica, duplicazioni e incongruenze semantiche ha reso necessaria un'importante fase di *preprocessing*. In diversi casi è stato necessario procedere con imputazioni, eliminazione di righe incomplete oppure esclusione di intere variabili ritenute troppo compromesse. Questo implica che il grafo finale rappresenta anche il risultato di scelte di semplificazione che possono aver comportato perdita di informazione.

Perimetro del grafo. Il grafo costruito è stato ristretto alle entità e alle relazioni per cui era possibile ricostruire con sufficiente affidabilità il percorso principale tra stazione appaltante, bando, aggiudicazione e aggiudicatario. Di conseguenza, alcune componenti potenzialmente rilevanti del sistema degli appalti non sono ancora state incluse nel modello attuale.

Sviluppi futuri

Proprio da questi limiti emergono le principali direzioni di sviluppo futuro. Una prima possibile espansione riguarda l'ampliamento della struttura del grafo, attraverso l'introduzione di nuove tipologie di nodi e relazioni, in particolare le procedure relative agli *SmartCIG* e i subappalti. Un'altra direzione promettente consiste nell'inclusione di informazioni temporali, così da trasformare il grafo statico attuale in una struttura dinamica. Dal punto di vista modellistico, si potrebbero valutare architetture più profonde e decoder più espressivi, nonché una fase di ottimizzazione sistematica degli iperparametri.

Riferimenti bibliografici

- [1] Q. Wang, G. Pang, M. Salehi, W. Buntine, C. Leckie. *Cross-Domain Graph Anomaly Detection via Anomaly-Aware Contrastive Alignment*. In: *AAAI Conference on Artificial Intelligence*, 2023.
- [2] S. Yang, B. Zhang, S. Feng, Z. Tan, Q. Zheng, J. Zhou, M. Luo. *AHEAD: A Triple Attention Based Heterogeneous Graph Anomaly Detection Approach*. In: *IEEE Transactions on Knowledge and Data Engineering*, 2023.
- [3] K. Ding, J. Li, R. Bhanushali, H. Liu. *Deep Anomaly Detection on Attributed Networks*. In: *SIAM International Conference on Data Mining (SDM)*, 2019.
- [4] S. Bandyopadhyay, N. Lokesh, S. V. Vivek, M. N. Murty. *Outlier Resistant Unsupervised Deep Architectures for Attributed Network Embedding*. In: *International Conference on Web Search and Data Mining (WSDM)*, 2020.
- [5] A. Roy, J. Shu, J. Li, C. Yang, O. Elshocht, J. Smeets, P. Li. *GAD-NR: Graph Anomaly Detection via Neighborhood Reconstruction*. In: *International Conference on Web Search and Data Mining (WSDM)*, 2024.
- [6] H. Qiao, H. Tong, B. An, I. King, C. Aggarwal, G. Pang. *Deep Graph Anomaly Detection: A Survey and New Perspectives*. In: *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, 2025.
- [7] L. Zhao, S. Sawlani, A. Srinivasan, L. Akoglu. *Graph Anomaly Detection with Unsupervised GNNs*. In: *IEEE International Conference on Data Mining (ICDM)*, 2022.
- [8] R. Fathony, J. Ng, J. Chen. *Interaction-Focused Anomaly Detection on Bipartite Node-and-Edge-Attributed Graphs*. In: *International Joint Conference on Neural Networks (IJCNN)*, 2023.
- [9] Y. Zheng, M. Jin, Y. Liu, L. Chi, K. T. Phan, Y.-P. P. Chen. *Generative and Contrastive Self-Supervised Learning for Graph Anomaly Detection*. In: *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, 2021.
- [10] Autorità Nazionale Anticorruzione (ANAC). *Portale dei dati aperti dell'ANAC*. Disponibile all'indirizzo: <https://dati.anticorruzione.it/opendata/> (accesso: febbraio 2026).
- [11] L'Arena. *Serit, indagati e perquisizioni in sede e all'Amia*. Disponibile all'indirizzo: <https://www.larena.it/territorio-veronese/garda-baldo/serit-indagati-e-perquisizioni-in-sede-e-all-amia-1.5450847> (accesso: aprile 2026).
- [12] Stampa Libera. *L'inchiesta "Vasi Comunicanti" è un flop: archiviazione per il direttore di cardiologia Antonio Micari e per tutti gli altri indagati*. Disponibile all'indirizzo: <https://www.stampalibera.it/2024/12/05/linchiesta-vasi-comunicanti-e-un->

[flop-archiviazione-per-il-direttore-di-cardiologia-antonio-micari-e-per-tutti-gli-altri-indagati/](#) (accesso: aprile 2026).

- [13] Repubblica (Finanza). *Netweek, indebitamento finanziario netto a 3,7 milioni di euro al 30 aprile*. Disponibile all'indirizzo: https://finanza.repubblica.it/News/2025/05/30/netweek_indebitamento_finanziario_netto_a_3_7_milioni_di_euro_al_30_aprile-139/ (accesso: aprile 2026).
- [14] ViterboToday. *Corte dei Conti a Toscana, 22 gennaio 2024*. Disponibile all'indirizzo: <https://www.viterbotoday.it/cronaca/corte-dei-conti-a-tuscania-22-gennaio-2024.html> (accesso: aprile 2026).
- [15] La Provincia di Como. *Bufera sulla variante, tangenti all'Anas: 850mila euro per avere i lavori*. Disponibile all'indirizzo: https://www.laprovinciadico.com.it/stories/premium/lago-e-valli/bufera-sulla-variante-tangenti-allanas-850mila-euro-avere-lavori-o_2529921_11/ (accesso: aprile 2026).
- [16] Laquila Blog. *Sentenza del Consiglio di Stato: confermata la legittimità dei commissariamenti a Barete*. Disponibile all'indirizzo: <https://www.laquilablog.it/sentenza-del-consiglio-di-stato-confermata-la-legittimita-dei-commissariamenti-a-barete/> (accesso: aprile 2026).
- [17] Luigi Boschi. *Policlinico Umberto I: 20 indagati, Montaguti contro tutti*. Disponibile all'indirizzo: https://luigiboschi.it/argomenti/benessere_e_salute/POLICLINICO-UMBERTO-I-20-INDAGATI-MONTAGUTI-CONTRO-TUTTI/ (accesso: aprile 2026).
- [18] T. Lazzari, A. Bortolato, G. Gomiero. *Appendice: Pulizia dei dati – Anomaly Detection su Grafi Eterogenei per la Pubblica Amministrazione Italiana*. Report tecnico, Aprile 2026.